

Détection de review bombing sur les avis Steam

Chaîne complète de data science : collecte, stockage, ETL, analyse exploratoire, machine learning et interface de démonstration

Réalisé par
Rostom SAMAR & Denis POPESCU
Master 1 Expert en Intelligence Artificielle

1. Problématique

Les avis Steam n'existant qu'après l'achat d'un jeu, la problématique retenue n'est pas de prédire le succès d'un jeu avant sa sortie, mais de détecter les épisodes de **review bombing** : des vagues d'avis négatifs concentrées dans le temps, déclenchées par un événement externe (changement d'économie de jeu, décision d'éditeur, controverse), et déconnectées de la qualité réelle du jeu.

Hypothèses de travail

- Un épisode de review bombing se traduit par une anomalie de volume d'avis, mais un pic de volume seul peut aussi correspondre à un simple regain de popularité, sans lien avec une controverse.
- Le texte d'un avis porte, à lui seul, un signal suffisant pour distinguer un avis écrit pendant un épisode de review bombing d'un avis normal, indépendamment des statistiques de volume ou de négativité.
- Les métadonnées numériques d'un avis (temps de jeu, longueur, historique de l'auteur) prédisent la recommandation ou l'utilité perçue d'un avis.

Solutions envisagées

- Détection statistique des anomalies de volume et de négativité par jeu, à partir de l'historique temporel des avis.
- Classification supervisée du texte des avis (TF-IDF et variantes) pour prédire un profil de review bombing sans recourir aux statistiques de volume.
- Clustering non supervisé pour vérifier si une structure thématique liée au review bombing émerge naturellement du texte, sans étiquette.

2. Dataset

Caractéristique	Valeur
Source	Steam Reviews (Kaggle, kieranpoc/steam-reviews)
Volume brut	113,9 millions de lignes, 39,6 Go décompressés
Structure	Avis (texte, note, votes), métadonnées joueur, jeu, timestamps
Volume filtré	32,3 millions d'avis, 506 jeux

Défis d'exploitation : volume trop important pour un traitement cloud gratuit fiable ; une première estimation du volume, obtenue via une session Colab instable, s'est révélée incomplète (téléchargement tronqué par une coupure réseau), corrigée par un téléchargement local fiable donnant le volume réel ci-dessus ; couverture partielle du catalogue Steam (certains jeux, comme Helldivers 2, sont absents du dataset).

Stratégie de filtrage : sélection combinant des jeux à controverse documentée (War Thunder, Cyberpunk 2077, Team Fortress 2, Grand Theft Auto V, etc.) et les jeux les plus reviewés, plutôt qu'un échantillonnage aléatoire, qui aurait dilué les épisodes rares recherchés.

3. Stockage

Choix retenu : SQL, via DuckDB, plutôt que NoSQL. Justification : données tabulaires à schéma fixe, analyse fondée sur des agrégations (comptages, corrélations), pas de besoin de flexibilité de schéma. DuckDB permet en outre un traitement entièrement local, sans compte cloud ni quota.

Optimisation	Résultat mesuré
Indexation (game, timestamp_created, voted_up)	0,828 s -> 0,044 s (environ 19x)
Partitionnement par jeu	0,084 s sur la même requête

4. Pipeline ETL

- **Extraction** : filtrage du CSV brut par jeu et langue anglaise, en un seul passage streamé (DuckDB), sans jamais charger le fichier complet en mémoire.
- **Transformation** : suppression des doublons (136 866) et des avis sans texte (12 334), conversion des timestamps, vérification de l'encodage binaire, normalisation z-score de cinq variables numériques.
- **Chargement** : table reviews_clean en base DuckDB (32 176 434 lignes), export Parquet pour les notebooks d'analyse.
- **Automatisation** : pipeline exécuté par une série de scripts Python autonomes, sans intervention manuelle.

5. Analyse exploratoire (EDA)

88,36 % des avis du dataset filtré sont positifs. Les corrélations entre métadonnées numériques et recommandation restent toutes proches de zéro (valeur absolue inférieure à 0,1) : le temps de jeu, la longueur de l'avis ou l'historique de l'auteur ne prédisent pas la recommandation.




Figure 1 - Vingt jeux les plus reviewés dans le dataset filtré.

Détection d'anomalies

War Thunder (17 au 19 mai 2023) combine une anomalie de volume extrême (z-score de 29,2, la plus élevée de l'analyse) et un taux d'avis négatifs de 88 %, contre 26 % en moyenne habituelle : review bombing confirmé. Cyberpunk 2077 (décembre 2020), malgré un volume spectaculaire au lancement, ne présente qu'un écart de négativité de 5,7 points par rapport à sa moyenne : un pic d'attention lié à la sortie, pas un review bombing.




Figure 2 - Anomalies de volume détectées sur trois jeux à controverse documentée.

Conclusion clé : un pic de volume seul ne suffit pas à identifier un review bombing ; il faut le croiser avec un écart de négativité pour le confirmer.

6. Machine learning

Apprentissage supervisé

Étiquette dérivée de la règle validée en EDA (z-score de volume supérieur à 3 et écart de taux négatif supérieur à 0,20), appliquée aux 506 jeux du dataset filtré : 270 034 avis positifs, équilibrés à raison d'un positif pour cinq négatifs pour l'entraînement.

Modèle	Précision	Recall	F1 (review bombing)
Régression logistique (TF-IDF)	0,50	0,75	0,600
Naïve Bayes complémentaire	0,47	0,76	0,577
Régression logistique + LSA (100 comp.)	0,41	0,68	0,509



Figure 3 - Matrices de confusion, régression logistique et Naive Bayes.

La réduction sémantique (LSA) dégrade la performance par rapport au TF-IDF brut : le signal utile tient à des termes lexicaux précis, pas à une structure sémantique large. Une tentative d'embeddings de phrase (sentence-transformers) a été abandonnée suite à un bug confirmé et non résolu dans les versions récentes de la librairie transformers (voir section 9, Difficultés rencontrées).

Apprentissage non supervisé

Clustering k-means (TF-IDF puis LSA à 50 composantes) sur l'ensemble du corpus, nombre de clusters choisi par score de silhouette (k=2 retenu, score de 0,474).




Figure 4 - Score de silhouette selon le nombre de clusters.




Figure 5 - Taille des clusters et proportion de review bombing par cluster.

Le découpage obtenu est très déséquilibré (95,2 % contre 4,8 %). Le cluster minoritaire présente une proportion de review bombing de 4,65 %, trois fois plus faible que le cluster majoritaire (17,27 %) et que la moyenne générale (16,7 %) : c'est l'inverse de l'hypothèse formulée en introduction. Le clustering ne fait pas émerger de groupe qui concentre les avis de review bombing.




Figure 6 - Projection en deux dimensions, colorée par cluster puis par étiquette réelle.

Résultat négatif mais informatif : la structure géométrique globale du texte ne suffit pas à isoler le review bombing sans étiquette. Sa détection repose sur un signal supervisé fin, pas sur une thématique visible sans apprentissage dirigé.

7. Évaluation et choix du modèle

Le modèle retenu pour l'interface de démonstration est la **régression logistique sur TF-IDF brut** (F1 = 0,600 sur la classe review bombing). Le recall est privilégié sur la précision : manquer un épisode de review bombing coûte plus cher, pour l'usage visé, qu'une fausse alerte occasionnelle.

8. Interface de démonstration

Application Streamlit (app.py), organisée en trois onglets : visualisation des données (choix d'un jeu, courbe du volume quotidien d'avis avec anomalies), prédiction (saisie libre d'un avis ou exemple réel tiré du jeu de données, prédiction et termes influents), et méthodologie (rappel des définitions et limites).

Lancement : `pip install streamlit` puis `streamlit run app.py`.

9. Difficultés rencontrées

- **Instabilité Google Colab** : plantages RAM, coupures réseau causant des téléchargements tronqués, sessions non persistantes, ayant motivé le passage à un traitement entièrement local avec DuckDB.
- **Téléchargement initial incomplet** : une première estimation du volume (obtenue via Colab, environ 21 Go) s'est révélée tronquée par une coupure réseau ; un téléchargement local fiable a donné le volume réel (39,6 Go, 113,9 millions de lignes), nécessitant de revalider la liste des jeux ciblés.
- **Environnement Python local** : décalage entre l'interpréteur du terminal et celui du noyau Jupyter, scan antivirus ralentissant l'accès aux fichiers volumineux.
- **Conflits de dépendances** (sentence-transformers, transformers, torch) : bug confirmé et documenté publiquement (renommage interne incohérent d'une classe centrale de transformers, introduit en octobre 2025), non résolu malgré plusieurs tentatives de correction, conduisant à remplacer les embeddings de phrase par une méthode LSA sans dépendance instable.

10. Conclusion

Le projet met en place une chaîne complète, de la collecte à la démonstration, pour détecter les épisodes de review bombing dans les avis Steam. Les résultats confirment que ni les métadonnées numériques, ni le volume d'avis pris isolément, ni une structure sémantique large ne suffisent à identifier un review bombing : sa détection repose sur un signal textuel précis, appris de manière supervisée, avec un recall d'environ 0,75 sur la classe recherchée. Ce résultat, obtenu et documenté à chaque étape malgré plusieurs obstacles techniques rencontrés en cours de projet, répond à la problématique et aux hypothèses posées en introduction.